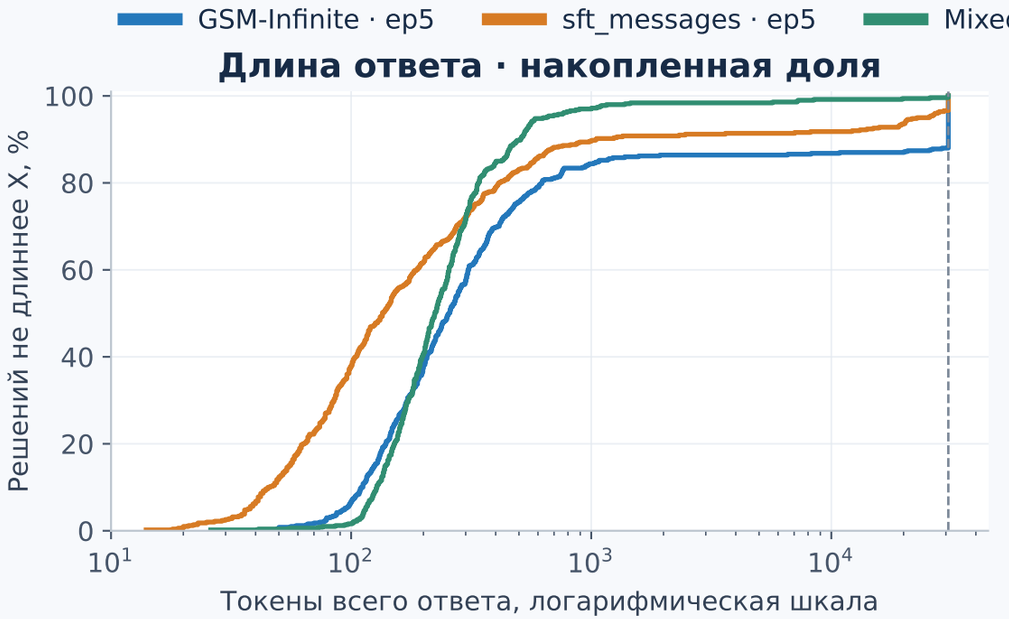
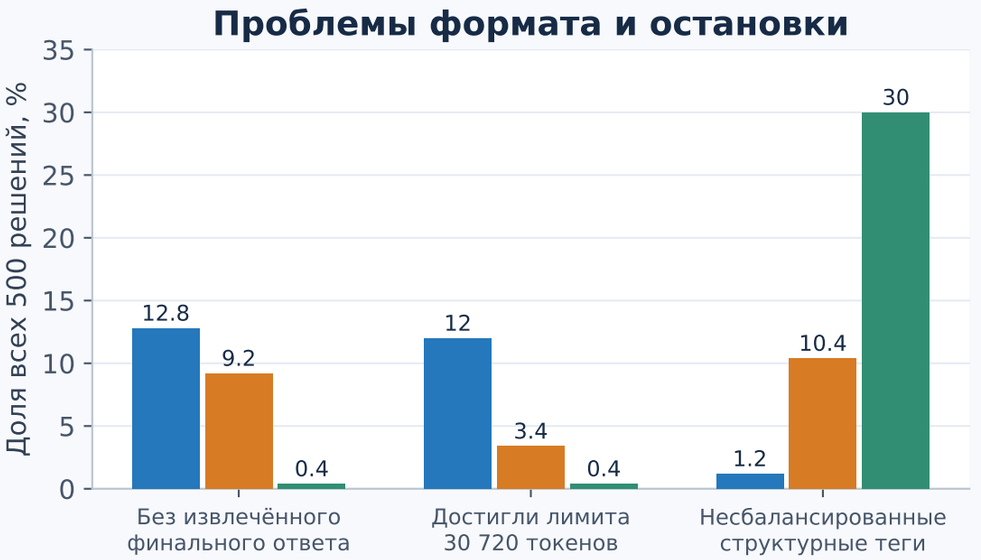
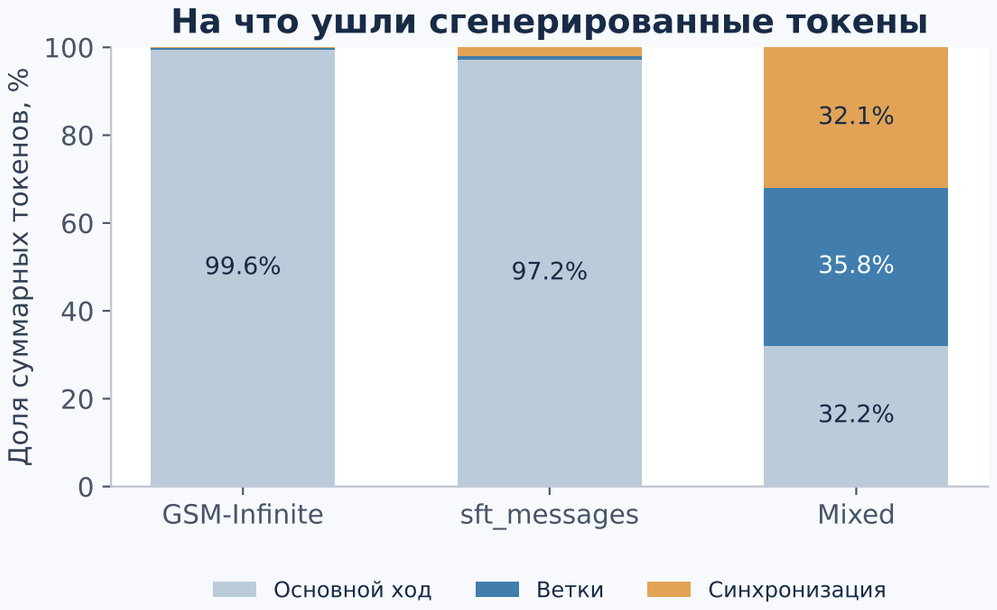
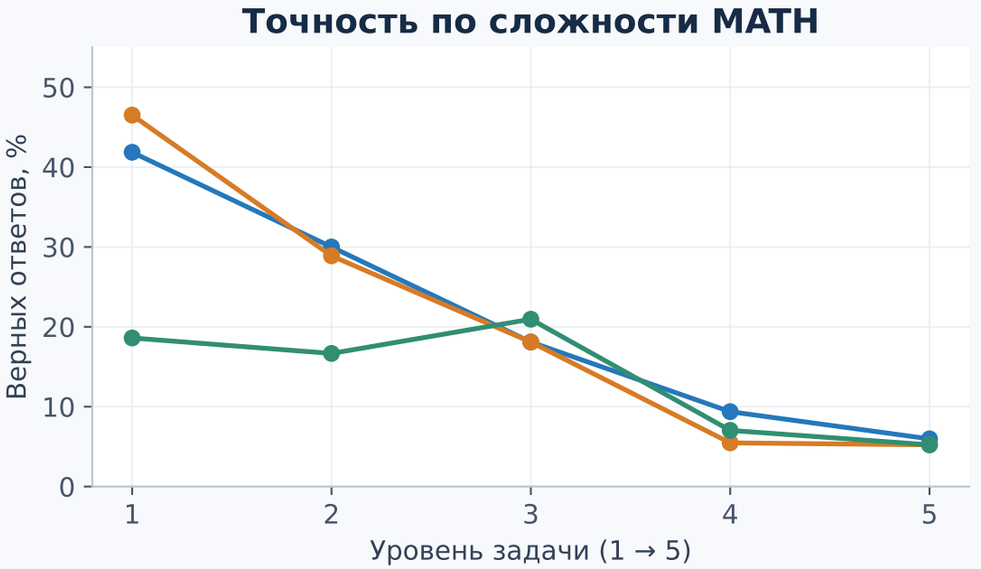
Что происходит внутри решений









Доли токенов взвешены по длине: длинные зацикленные ответы сильно влияют на GSM и sft_messages.

Ограничение оценки: vLLM-продолжение не применяет custom Unseen mask/positions к объединённому контексту.